

Идентификация последовательности HBB

Автор: Egor Fedosov. Stepik ID: 1370242994.
Задание NGS: описание индивидуально полученной последовательности. Дата анализа: 5 сентября 2026 г. Все действия после получения файла выполнены на локальной копии.

Краткий вывод

Поле	Результат
Идентифицированный ген	HBB - hemoglobin subunit beta (бета-глобин).
Организм	Homo sapiens (человек), NCBI Taxonomy ID 9606.
Тип входных данных	Белковая FASTA-последовательность длиной 147 аминокислот , а не нуклеотидная последовательность.
Основание идентификации	Reviewed UniProtKB/Swiss-Prot accession P68871 , имя записи HBB_HUMAN, полное совпадение длины и последовательности.

1. Получение и первичная проверка файла

05.09.2026 выполнен вход ssh -p 8126 bioinf3_abit@smp4.icgbio.ru и единственный запрос bioinf3-testtask. Введены Egor, Fedosov и Stepik ID 1370242994. Программа назначила архив **A114.fasta.gz**; он скачан через scp, серверная сессия завершена. Анализ выполнен локально. Повторять запрос задания для воспроизведения не нужно: исходный архив приложен к репозиторию. Ниже приведены команды, запускавшиеся из корня репозитория. Они позволяют воспроизвести чтение исходного файла и контроль целостности.

```
$ file NGS/input/A114.fasta.gz
$ gzip -cd NGS/input/A114.fasta.gz
$ shasum -a 256 NGS/input/A114.fasta.gz
```

Archive SHA-256:
1daa852d387c52ca6c7702821635c1048850050e0352c27501f74fd49c634682

Заголовок распакованной записи: >sp|P68871|HBB_HUMAN Hemoglobin subunit beta OS=Homo sapiens OX=9606 GN=HBB PE=1 SV=2. Маркер sp обозначает reviewed запись Swiss-Prot; далее уже содержатся accession P68871, название HBB_HUMAN, организм, taxonomy ID и символ гена. Последовательность состоит из стандартных однобуквенных символов аминокислот (включая E, F, L и P, не входящие в алфавит ДНК) и имеет длину 147. Это белковая FASTA-запись.

```
MVHLTPEEKS AVTALWGKVN VDEVGGEALG RLLVVYPWTQ RFFESFGDLS
TPDAVMGNPK VKAHGKKVLG AFSDGLAHLD NLKGTFTLS ELHCDKLHVD
PENFRLLGNV LVCVLAHFG KEFTPPVQAA YQKVAVGVAN ALAHKYH
```

2. Независимая аннотация по публичным идентификаторам

Заголовок дает проверяемую гипотезу: HBB человека. Проверяю ее по UniProtKB P68871 и NCBI Gene 3043, затем сравниваю сами аминокислоты с отдельно скачанной эталонной записью. BLAST не запускался: при известном accession и полном совпадении с эталоном прямое сравнение позволяет проверить эту гипотезу без поиска по сходству.

Шаг	Инструмент и точный запрос	Промежуточный результат и интерпретация
1	UniProtKB: запрос P68871 UniProtKB P68871	Reviewed запись P68871 = HBB_HUMAN. Название: hemoglobin subunit beta; ген: HBB; организм: Homo sapiens; длина: 147 aa; evidence at protein level.
2	NCBI Gene: запрос HBB Homo sapiens, Gene ID 3043 NCBI Gene 3043	Официальный символ HBB, protein-coding gene. RefSeq protein NP_000509.1; связанный UniProtKB accession P68871. Ген расположен на хромосоме 11 (GRCh38.p14).
3	Локальный скрипт NGS/verify_sequence.py; эталон NGS/reference/P68871.fasta	Обе последовательности длиной 147 aa. Совпадают 147 из 147 позиций; идентичность 100%, покрытие по длине 100%, замен и разрывов 0.

Точная проверка последовательности

05.09.2026 эталон скачан с официального UniProt REST API. Сохраненная копия позволяет повторить сравнение без сети. Скрипт использует только стандартную библиотеку Python 3: проверяет SHA-256 архива, число FASTA-записей, аминокислотный алфавит, длину и равенство последовательностей.

```
# From the repository root, Python 3.9+
python3 NGS/verify_sequence.py
```

```
# Observed results
Length: 147 aa
Exact positional matches: 147 / 147
Identity: 100.0%; length coverage: 100.0%
Sequence SHA-256:
9ebf320eb707d71644444fe5006ed58af56a0bf0ec9568eb6a3a65e0e8191465
```

Адрес скачивания: <https://rest.uniprot.org/uniprotkb/P68871.fasta>.

SHA-256 сохраненного эталонного FASTA: a976e8ef07b298781398d4a66d52ddf13b796e991baa7e4e499732ecc6689107.

Биологическая интерпретация

HBB кодирует бета-цепь гемоглобина. Взрослый гемоглобин HbA представляет собой тетрамер из двух альфа- и двух бета-цепей; белок участвует в переносе кислорода. В рамках задания организм установлен по OS/OX и аннотации эталона. Само совпадение с одной белковой записью не доказывает уникальность видового происхождения: консервативные белки могут совпадать у близких видов. Человек указан как организм исходной записи; дополнительный модельный вид не назначается.

3. Связь с публикацией

Выбрана обзорная статья о редактировании генов при гемоглобинопатиях человека. При повторной проверке запись найдена в Europe PMC по точному запросу EXT_ID:40252393 AND SRC:MED; проверены DOI, название, автор и поле Abstract. Обзор релевантен заданию, хотя не является отдельным экспериментом.

Подходящая работа: Almasoudi H.H. Therapeutic promise of CRISPR-Cas9 gene editing in sickle cell disease and beta-thalassemia: A current review. Current Research in Translational Medicine (2025). DOI: **10.1016/j.retram.2025.103513**; PMID: 40252393.

“Mutations in the hemoglobin subunit beta (HBB) gene are responsible for causing both BT and SCD.”

Это предложение из Abstract напрямую связывает HBB с двумя клинически важными гемоглобинопатиями - бета-талассемией и серповидноклеточной болезнью. Оно релевантно найденному гену и организму Homo sapiens; цитата не означает, что в предоставленной последовательности обнаружен патогенный вариант. В обзоре обсуждаются механизмы редактирования, способы доставки и ограничения CRISPR-Cas9 для этих заболеваний.

4. Итог и воспроизводимость

Последовательность идентифицирована как канонический белок HBB человека - hemoglobin subunit beta. Локальная проверка FASTA, accession lookup в UniProtKB и независимая запись NCBI Gene дают согласованные результаты. Для повторения вычислительной проверки достаточно архива, эталонного FASTA и скрипта из репозитория. Все контрольные суммы и результаты сравнения приведены выше. Интернет требуется только для повторной проверки актуальной аннотации и библиографии. По аминокислотной последовательности не восстанавливаются однозначно кодоны, интроны и нуклеотидные варианты. Анализ не устанавливает генотип конкретного человека.

Порядок воспроизведения из корня репозитория:

1. Проверить архив командой `gzip -t NGS/input/A114.fasta.gz`.
2. Запустить `python3 NGS/verify_sequence.py`.
3. Убедиться в результате 147/147 и совпадении SHA-256 с журналом.
4. Открыть приведенные ниже ссылки, сверить ген, организм, DOI и цитату.

Источники и дата доступа

UniProtKB P68871: <https://www.uniprot.org/uniprotkb/P68871/entry>

NCBI Gene 3043: <https://www.ncbi.nlm.nih.gov/gene/3043>

PubMed PMID 40252393: <https://pubmed.ncbi.nlm.nih.gov/40252393/>

Europe PMC, запись MED/40252393: <https://europepmc.org/article/MED/40252393>

DOI статьи: <https://doi.org/10.1016/j.retram.2025.103513>

Дата работы с источниками: 05.09.2026. Эталон сохранен в NGS/reference/P68871.fasta.